🏛 BỘ CÔNG THƯƠNG • ĐẠI HỌC CÔNG NGHIỆP TP.HCM (IUH) • KHOA CNTT

Thu Thập Và Phân Tích Dữ Liệu Khám Phá Nhằm Đánh Giá Xu Hướng Thị Trường Sách Trực Tuyến Fahasa

[Stage 1 & Stage 2 - Data Preprocessing, EDA & Model Architecture] • GVHD: PHẠM THỊ XUÂN HIỀN

1. NHÓM TRƯỞNG
Trần Tấn Đức
MSSV: 24643701

2. THÀNH VIÊN
Lê Anh Dũng
MSSV: 24743951

3. THÀNH VIÊN
Dương Danh Dũng
MSSV: 24640801

4. THÀNH VIÊN
Nguyễn Tiến Đạt
MSSV: 24708521

GIỚI THIỆU TỔNG QUÁT ĐỀ TÀI NGHIÊN CỨU // NHÓM 4

Tổng Quan Lộ Trình Khai Phá Dữ Liệu Sách Trực Tuyến Fahasa

1. Thu Thập & Lưu Trữ

Cào 923 bản ghi Fahasa lưu lên MongoDB Atlas.

2. Tiền Xử Lý (Stage 1)

Làm sạch còn 598 dòng chuẩn và tạo biến mới.

3. Phân Tích Khám Phá

Tìm quy luật phân phối giá và lượng bán.

4. Mô Hình (Stage 2)

Thực nghiệm PCA, K-Means, Hồi quy và Phân loại.

PHẦN 1 // 1.1.a. MÃ NGUỒN THU THẬP CHI TIẾT SẢN PHẨM (HÌNH 1.3)

Đoạn Code Duyệt Link Và Trích Xuất Thuộc Tính Từng Cuốn Sách

```
product_links = page.evaluate(js_extraction_code)[:target_records]
for index, item in enumerate(product_links, start=1):
    try:
        page.goto(item['ProductURL'], wait_until='domcontentloaded', timeout=45000)
        breadcrumb_items = page.locator('.breadcrumb li a').all_inner_texts()
        category = " > ".join([b.strip() for b in breadcrumb_items if b.strip()])
        def get_table_data(label):
            loc = page.locator(f'th.table-label:has-text("{label}") + td')
            return loc.first.inner_text().strip() if loc.count() > 0 else "N/A"
        item_data = {
            'ProductName': item['ProductName'], 'Price': item['Price'],
            'QuantitySold': item['QuantitySold'], 'Category': category,
            'Author': get_table_data("Tác giả"), 'Publisher': get_table_data("NXB"),
            'Supplier': get_table_data("Nhà Cung Cấp"),
            'CoverType': get_table_data("Hình thức"), 'Pages': get_table_data("Số trang"),
            'ProductURL': item['ProductURL'] }
        crawled_data.append(item_data)
    except Exception as e:
        item.update({'Category': 'N/A', 'Author': 'N/A', 'Publisher': 'N/A', 'Supplier': 'N/A', 'CoverType': 'N/A', 'Pages': 'N/A'})
        crawled_data.append(item)
    time.sleep(1)
```

PHẦN 1 // 1.1.a. KẾT QUẢ DỮ LIỆU RÚT RA SAU KHI CHẠY CODE

Dữ Liệu Rút Ra Được Ra Sao Và Có Cấu Trúc Thế Nào?

Quy Mô 923 Dòng Chuẩn

Mỗi dòng là một sản phẩm sách hoặc văn phòng phẩm.

4 Thông Tin Bề Mặt

Gồm Tên sách, Giá bán, Số lượng đã bán và Link gốc.

6 Thông Tin Chi Tiết

Gồm Ngành hàng, Tác giả, NXB, Nhà cung cấp, Loại bìa, Số trang.

Collection Fahasa_Trending (923 Documents • 10 Thuộc Tính Cốt Lõi)

- **Cụm máy chủ Cluster0:** Cơ sở dữ liệu Fahasa trên MongoDB Atlas.
- **Fahasa_Trending:** Lưu trữ 923 documents dữ liệu tĩnh gốc.
- **10 thuộc tính tĩnh:** ProductName, Price, QuantitySold, Category, Author...

```
MongoDB Compass — Fahasa.Fahasa_Trending (Documents: 923)

_id: ObjectId('6abbf7a665841c522ff6d9dd')
ProductName: "Xứ Sở Miên Man - Phiên Bản Book Charm - Bìa Cứng"
Price: 415000
QuantitySold: 1000
Category: "SÁCH TIẾNG VIỆT > VĂN HỌC > TIỂU THUYẾT"
Author: "Jun Phạm"
Publisher: "Phụ Nữ Việt Nam"
Supplier: "Skybooks"
CoverType: "Bìa Cứng"
Pages: 456
ProductURL: "https://www.fahasa.com/xu-so-mien-man-phien-ban..."
```

Tích Hợp Đa Nguồn & Collection Fahasa_cleaned (598 Documents)

MongoDB Compass — Fahasa.Fahasa_cleaned (Documents: 598)

```
_id: ObjectId('6ad88cd432e9fe2debccf4ac')
ProductName: "Xứ Sở Miên Man - Phiên Bản Book Charm - Bìa Cứng"
Price: 415000 | QuantitySold: 1000 | Pages: 456
Lvl1: "SÁCH TIẾNG VIỆT" | Lvl2: "VĂN HỌC"
Pages_missing: false
Price_clip: 411875 | QuantitySold_clip: 1000 | Pages_clip: 456
log_Price: 5.6180480967120925 | log_Qty: 3.000434077479319
Is_set: false | Has_gift: false | Campaign: "DEAL_HOT_PAGES"
Price_bin: "200-500k" | Price_per_page: 910.0877 | Bestseller: 0
```

Sinh dữ liệu động: Dùng random, Faker và Prompt Engineering.

Tích hợp dữ liệu: Nối dọc pd.concat và nối ngang Left Join pd.merge.

Fahasa_cleaned: Lưu trữ dữ liệu sạch đã qua lọc IQR và tạo biến.

Kết Nối Cơ Sở Dữ Liệu MongoDB Atlas Và Tải Dữ Liệu

```
import pandas as pd, numpy as np
import matplotlib.pyplot as plt, seaborn as sns
from pymongo import MongoClient

uri = "mongodb://mrin9379_db_user:...@cluster0...mongodb.net/..."
client = MongoClient(uri)
db = client['Fahasa']
collection = db['Fahasa_Trending']

cursor = collection.find({})
df = pd.DataFrame(list(cursor))
if '_id' in df.columns:
    df.drop(columns=['_id'], inplace=True)
display(df.head())
# Dự phòng: df = pd.read_csv('../Data/fahasa_dataset.csv')
```

Thư viện PyMongo: Kết nối trực tiếp Cluster0 qua chuỗi URI bảo mật.

Loại bỏ cột _id: Xóa định danh hệ thống MongoDB khi nạp DataFrame.

Phương án dự phòng: Đọc tệp CSV cục bộ khi mạng đám mây sự cố.

Kiểm Tra Khuyết Thiếu & Tách Phân Cấp Ngành Hàng

```
df_origin = df.copy()
print(df.shape) # (923, 10)
df.info()

miss = df.isna().sum().to_frame("n_missing")
miss["pct"] = (miss["n_missing"] / len(df) * 100).round(1)
print(miss[miss["n_missing"] > 0])

df["Lvl1"] = df["Category"].str.split(" > ").str[0]
df["Lvl2"] = df["Category"].str.split(" > ").str[1]
```

```
RangeIndex: 923 entries, 0 to 922
Data columns (total 10 columns):
 0 ProductName  923 non-null str
 1 Price        898 non-null float64
 2 QuantitySold 923 non-null int64
 8 Pages        848 non-null float64

       n_missing  pct
Price         25  2.7
Pages         75  8.1

# Tách Category thành Lvl1 & Lvl2 giúp
# tránh bùng nổ chiều One-Hot (Overfitting)
```

Loại Bỏ Dòng Trùng, Giá Âm & Số Lượng Bán Ảo

```
# Xóa các dòng trùng
print("Số dòng trùng:", df.duplicated().sum()) # 91
df = df.drop_duplicates().reset_index(drop=True)
print(df.shape) # (832, 12)

# Xóa giá trị không hợp lệ
bad_price = df["Price"] ⩽ 0
bad_qty   = df["QuantitySold"] ⩾ 999_999_999
print(bad_price.sum(), bad_qty.sum()) # 87 63
df = df[~(bad_price | bad_qty)].reset_index(drop=True)
print(df.shape) # (682, 12)

print((df["Price"] > 5_000_000).sum()) # 59
df = df[df["Price"] ⩽ 5_000_000].reset_index(drop=True)
print(df.shape) # (598, 12)
```

Xóa 91 dòng trùng: Đưa dữ liệu từ 923 xuống 832 dòng, chống rò rỉ Train/Test.

Lọc sai lệch logic: Xóa 87 dòng giá <= 0 và 63 dòng bán ảo >= 999 triệu.

Giới hạn ngưỡng giá: Loại 59 mặt hàng giá > 5 triệu VNĐ, còn 598 dòng.

Điền Khuyết Thông Minh Theo Đặc Thù Từng Nhóm Biến

Khoanh vùng is_book: Chỉ điền trung vị số trang cho Sách Tiếng Việt & Ngoại văn.

Nhóm Phi sách: Giữ nguyên 37 dòng VPP/Đồ chơi kèm cờ Pages_missing.

Biến phân loại: Điền 'Unknown', Mode cho Supplier và 'Không áp dụng'.

```
is_book = df["Lvl1"].isin(["SÁCH TIẾNG VIỆT", "FOREIGN BOOKS"])
df["Price"] = df["Price"].fillna(df["Price"].median())

df["Pages_missing"] = df["Pages"].isna()
med_pages = df.loc[is_book, "Pages"].median()
df.loc[is_book & df["Pages"].isna(), "Pages"] = med_pages

for c in ["Category", "Lvl1", "Lvl2", "Author", "Publisher"]:
    df[c] = df[c].fillna("Unknown")
df["Supplier"] = df["Supplier"].fillna(df["Supplier"].mode()[0])

df.loc[~is_book & df["CoverType"].isna(), "CoverType"] = "Không áp dụng"
df["CoverType"] = df["CoverType"].fillna(df.loc[is_book, "CoverType"].mode()[0])
# Kết quả isna().sum(): Tất cả = 0 (riêng Pages phi sách = 37 hợp lý)
```

Kiểm Định Assert & Giới Hạn Biên An Toàn (.clip)

```
assert (df["Price"] > 0).all()
assert (df["QuantitySold"] ⩾ 0).all()
assert df[["Price", "QuantitySold", "Category", "CoverType"]].isna().sum().sum() == 0
print("Sạch:", df.shape) # Sạch: (598, 13)

def iqr_fence(s, k=1.5):
    q1, q3 = s.quantile([0.25, 0.75])
    iqr = q3 - q1
    return q1 - k * iqr, q3 + k * iqr

for c in ["Price", "QuantitySold", "Pages"]:
    lo, hi = iqr_fence(df[c].dropna())
    n_out = ((df[c] < lo) | (df[c] > hi)).sum()
    df[c + "_clip"] = df[c].clip(lower=max(lo, df[c].min()), upper=hi)
# Price rào: -138325 411875 | outlier: 59
# QuantitySold rào: -9975 18425 | outlier: 59
# Pages rào: -130 718 | outlier: 29
```

Kiểm định Assert: Xác nhận 598 dòng sạch hoàn toàn lỗi âm và khuyết.

Rào tứ phân vị IQR: Phát hiện 59 ngoại lệ giá, 59 lượng bán và 29 số trang.

Winsorizing (.clip): Tạo cột _clip giữ nguyên mẫu mà không làm nhiễu mô hình.

Khởi Tạo Biến Logarit, Regex, One-Hot & Chuẩn Hóa Z-Score

Biến đổi Log10 & Z-score: Khắc phục phân phối lệch phải cho Price và Qty.

Trích xuất Regex: Tạo biến Is_set, Has_gift và chiến dịch Campaign.

Nhãn Bestseller: Top 25% sản lượng bán cao nhất và One-Hot Cover_*.

```
df["log_Price"] = np.log10(df["Price"])
df["log_Qty"]   = np.log10(df["QuantitySold"] + 1)

name = df["ProductName"].str.lower()
df["Is_set"]   = name.str.contains(r"boxset|combo|\(bộ |trọn bộ|hộp \d", regex=True)
df["Has_gift"] = name.str.contains("tặng kèm")
df["Campaign"] = df["ProductURL"].str.extract(r"fhs_campaign=(\w+)")[0]

df["Price_bin"] = pd.cut(df["Price"], [0, 50_000, 100_000, 200_000, 500_000, 5_000_000],
                         labels=["<50k", "50-100k", "100-200k", "200-500k", ">500k"])
df["Price_per_page"] = np.where(df["Pages"] > 0, df["Price"] / df["Pages"], np.nan)

top_q = df["QuantitySold"].quantile(0.75)
df["Bestseller"] = (df["QuantitySold"] ⩾ top_q).astype(int)
dummies = pd.get_dummies(df["CoverType"], prefix="Cover", dtype=int)
df = pd.concat([df, dummies], axis=1)
for c in ["log_Price", "log_Qty"]:
    df[c + "_z"] = (df[c] - df[c].mean()) / df[c].std()
```

PHẦN 2 & PHẦN 3 // KẾT QUẢ BIẾN MỚI FEATURE ENGINEERING (HÌNH 3.3)

Kiểm Tra Bảng Mẫu Các Đặc Trưng Đã Chuẩn Bị Cho Học Máy

```
fe_cols = [
    'Price_clip', 'log_Price', 'Price_bin',
    'Price_per_page', 'Cover_Bìa Cứng',
    'Is_set', 'Has_gift'
]
display(df_cleaned[fe_cols].sample(3))

# Kết quả hiển thị mẫu 3 dòng dữ liệu:
# ID   Price_clip  log_Price  Price_bin  Price_per_page  Is_set  Has_gift
# 516  76000.0     4.880814   50-100k    351.851852      False   False
# 160  105000.0    5.021189   100-200k   795.454545      False   True
# 574  117000.0    5.068186   100-200k   352.409639      False   False
```

1. Log transform: Biến đổi Logarit (log_Price, log_Qty) xử lý phân phối lệch phải.

2. Clipping & Binning: Ép trần/sàn Outliers (Price_clip) và chia khoảng giá (Price_bin).

3. Encoding & Giá/Trang: Mã hóa One-Hot loại bìa, Boolean và tạo chỉ số Price_per_page.

Cấu Trúc Tập Dữ Liệu Sạch & Đánh Giá Khuyết Hợp Lý (Valid Missing)

```
df.to_csv("../Data/fahasa_cleaned.csv", index=False, encoding="utf-8-sig")
df_cleaned = pd.read_csv('../Data/fahasa_cleaned.csv')
print("Kích thước (Shape):", df_cleaned.shape)
print(df_cleaned.dtypes.value_counts())

missing = df_cleaned.isnull().sum()
print(missing[missing > 0])
```

```
Kích thước (Shape): (598, 32)
str: 11 | float64: 9 | int64: 9 | bool: 3

Các cột có giá trị khuyết thiếu (Valid Missing):
Author            39
Publisher         38
CoverType         38
Pages / Pages_clip 37
Price_per_page    37
# Hợp lý vì VPP & Đồ chơi không có Tác giả, Số trang
```

Thống Kê Tỷ Lệ Outliers, Danh Mục Lvl1 & Độ Lệch Phải

```
for col in ['Price', 'QuantitySold', 'Pages']:
    Q1 = df_cleaned[col].quantile(0.25)
    Q3 = df_cleaned[col].quantile(0.75)
    IQR = Q3 - Q1
    outliers = ((df_cleaned[col] < (Q1 - 1.5*IQR)) |
                (df_cleaned[col] > (Q3 + 1.5*IQR))).sum()

print(df_cleaned['Lvl1'].value_counts())
print(df_cleaned['Campaign'].value_counts())
print(df_cleaned[['Price', 'QuantitySold']].describe().loc[['mean', '50%']])
```

```
Outliers Price: 59 (9.87%) | Qty: 59 (9.87%) | Pages: 29 (4.85%)

Phân phối danh mục cấp 1 (Lvl1):
SÁCH TIẾNG VIỆT: 500 | FOREIGN BOOKS: 61
VĂN PHÒNG PHẨM: 19   | ĐỒ CHƠI: 17 | LƯU NIỆM: 1

Campaign: DEAL_HOT_PAGES (568) | PERSONALIZE_PRODUCT (30)

Thống kê mô tả (Lệch phải nặng - Right-skewed):
       Price          QuantitySold
mean   216,154.40     11,715.17
50%    113,000.00      2,500.00
```

Ma Trận Tương Quan & Lượng Bán Trung Vị Theo Ngành Hàng, Loại Bìa

```
print("Hệ số tương quan:\n",
      df_cleaned[['log_Price', 'log_Qty', 'Pages']].corr())

print("\nLượng bán trung vị theo Lvl1:\n",
      df_cleaned.groupby('Lvl1')['QuantitySold']
      .median().sort_values(ascending=False))

print("\nLượng bán trung vị theo CoverType:\n",
      df_cleaned.groupby('CoverType')['QuantitySold']
      .median().sort_values(ascending=False))
```

```
Hệ số tương quan (Pearson):
           log_Price    log_Qty      Pages
log_Price   1.000000  -0.290668   0.397567
log_Qty    -0.290668   1.000000  -0.165452

Lượng bán trung vị theo Lvl1:
VĂN PHÒNG PHẨM: 9600.0 | ĐỒ CHƠI: 7500.0
SÁCH TIẾNG VIỆT: 2600.0 | FOREIGN BOOKS: 1400.0 | LƯU NIỆM: 934.0

Lượng bán trung vị theo CoverType:
Mixed Media: 6200.0 | Bìa Mềm: 2800.0 | Bìa Cứng: 1150.0
Bộ Hộp: 234.0       | Board Book: 127.0
```

PHẦN 3 // 3.3. TÓM TẮT PHÁT HIỆN & ĐIỂM LƯU Ý (SUMMARY & CAVEATS)

Những Gì Nghiệm Ra Được Từ Phân Tích Khám Phá (Stage 1)

💡 Tóm Lược Insight Cốt Lõi

Phi sách dẫn đầu: Văn phòng phẩm (9,600) và Đồ chơi (7,500) là gà đẻ trứng vàng về sản lượng trung vị.

Giá không phải rào cản: Khách mua vì nội dung độc bản; Bìa mềm (2,800) là định dạng an toàn nhất.

⚠️ Caveats (Những Điểm Cần Lưu Ý)

Mất cân bằng Campaign: 95% thuộc DEAL_HOT_PAGES nên chưa thể so sánh hiệu quả giữa các chiến dịch.

Thiếu biến thời gian (Datetime): Chưa đánh giá được tính mùa vụ (như dịp tựu trường Back-to-school).

Mã Nguồn Thiết Lập Khung Lưới 2x2 Grid Bằng Seaborn

```
sns.set_theme(style="whitegrid")
fig, axes = plt.subplots(2, 2, figsize=(20, 14))

# [0, 0] Heatmap Tương quan Spearman
corr_cols = ['Price', 'QuantitySold', 'Pages', 'log_Price', 'log_Qty', 'Has_gift', 'Is_set']
sns.heatmap(df[corr_cols].corr(method='spearman'), annot=True, fmt=".2f", cmap="coolwarm", ax=axes[0, 0])

# [0, 1] Boxplot log_Qty theo Nhóm cấp 1
sns.boxplot(data=df, x='log_Qty', y='Lvl1', ax=axes[0, 1])

# [1, 0] Violinplot log_Qty theo Loại bìa (3 loại chính)
main_covers = ['Bìa Cứng', 'Bộ Hộp', 'Bìa Mềm']
sns.violinplot(data=df[df['CoverType'].isin(main_covers)], x='CoverType', y='log_Qty', ax=axes[1, 0])

# [1, 1] Barplot Tỷ lệ Bestseller (Top 25%) theo Lvl2 (≥ 20 SP)
sns.barplot(x=bestseller_rates.values, y=bestseller_rates.index, color="#8e44ad", ax=axes[1, 1])
axes[1, 1].axvline(df['is_bestseller'].mean() * 100, color='black', linestyle='--')
```

Khung lưới 2x2: Tổng hợp 4 góc nhìn trực quan trên cùng Dashboard.

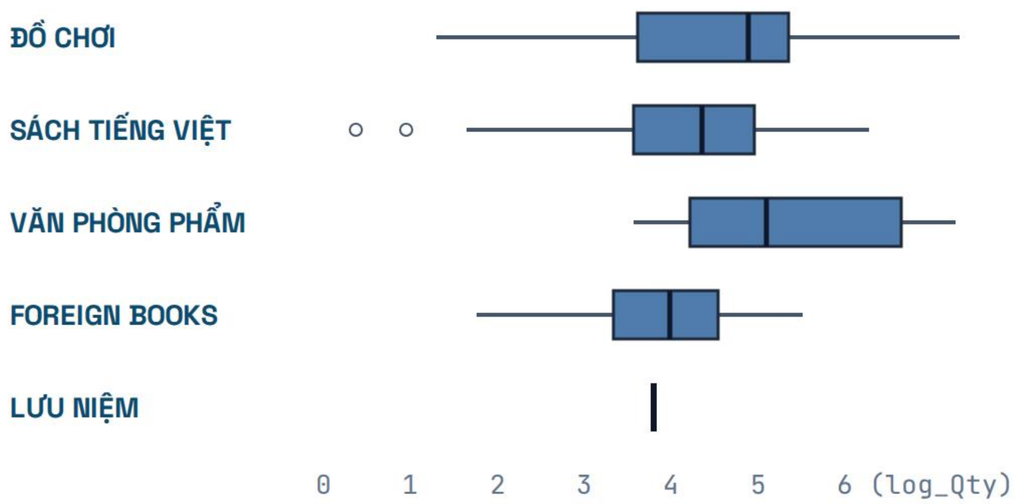
Spearman Correlation: Đánh giá tương quan hạng cho dữ liệu lệch.

Lọc nhóm >= 20 SP: Xếp hạng tỷ lệ Bestseller chính xác theo Lvl2.

OUTPUT [0, 0] & [0, 1] // KẾT QUẢ CHẠY CODE VISUALIZATION DASHBOARD

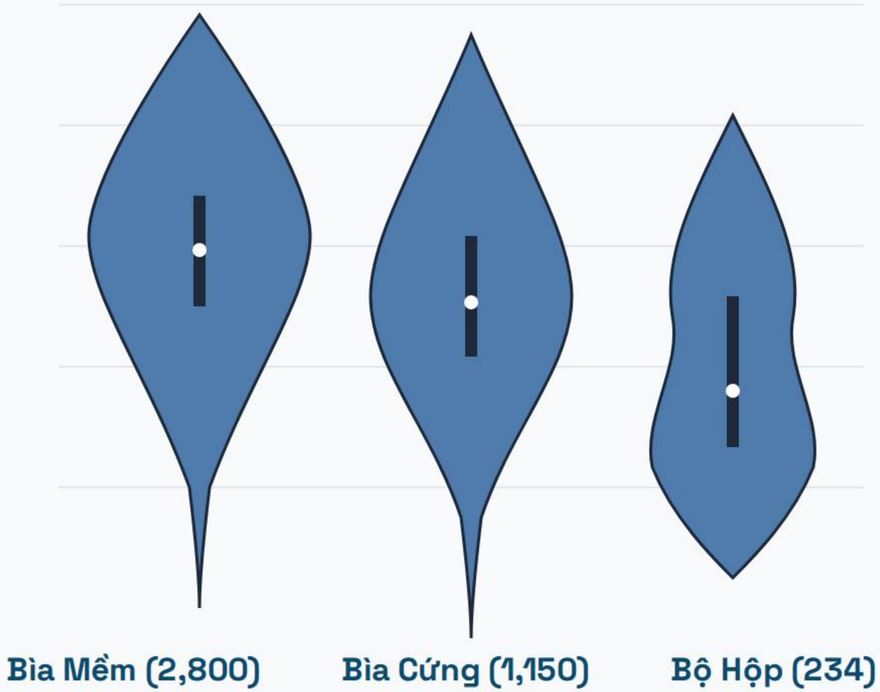
Tương Quan Spearman & Boxplot log10(Số Lượng Bán) Theo Nhóm Cấp 1

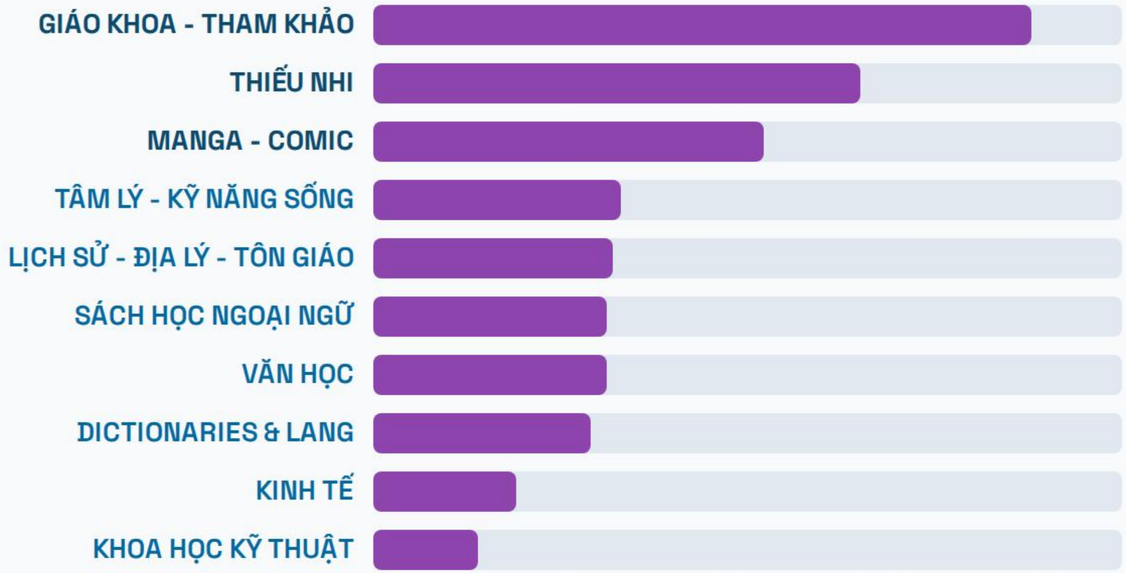
Biến	Price	Qty	Pages	logP	logQ	Gift	Set
Price	1.00	-0.30	0.44	1.00	-0.30	-0.06	-0.24
QtySold	-0.30	1.00	-0.20	-0.30	1.00	-0.02	0.08
Pages	0.44	-0.20	1.00	0.44	-0.20	-0.04	-0.12
log_Price	1.00	-0.30	0.44	1.00	-0.30	-0.06	-0.24
log_Qty	-0.30	1.00	-0.20	-0.30	1.00	-0.02	0.08
Has_gift	-0.06	-0.02	-0.04	-0.06	-0.02	1.00	0.34
Is_set	-0.24	0.08	-0.12	-0.24	0.08	0.34	1.00



OUTPUT [1, 0] & [1, 1] // KẾT QUẢ CHẠY CODE VISUALIZATION DASHBOARD

Violinplot Theo Loại Bìa & Tỷ Lệ Bestseller (Top 25%) Theo Nhóm Cấp 2





PHẦN 4 (STAGE 2): KIẾN TRÚC MÔ HÌNH & ĐÁNH GIÁ KẾT QUẢ

Hệ Thống Học Máy Toàn Diện Trên 593 Sản Phẩm Duy Nhất

TASK 01

Giảm Chiều PCA

Nén 17 thuộc tính về 10 PCs trực giao.

TASK 02

Phân Cụm K-Means

Phân khúc 5 nhóm mặt hàng tối ưu.

TASK 03

Hồi Quy Giá Bán

So sánh OLS và Decision Tree Regressor.

TASK 04

Phân Loại Bestseller

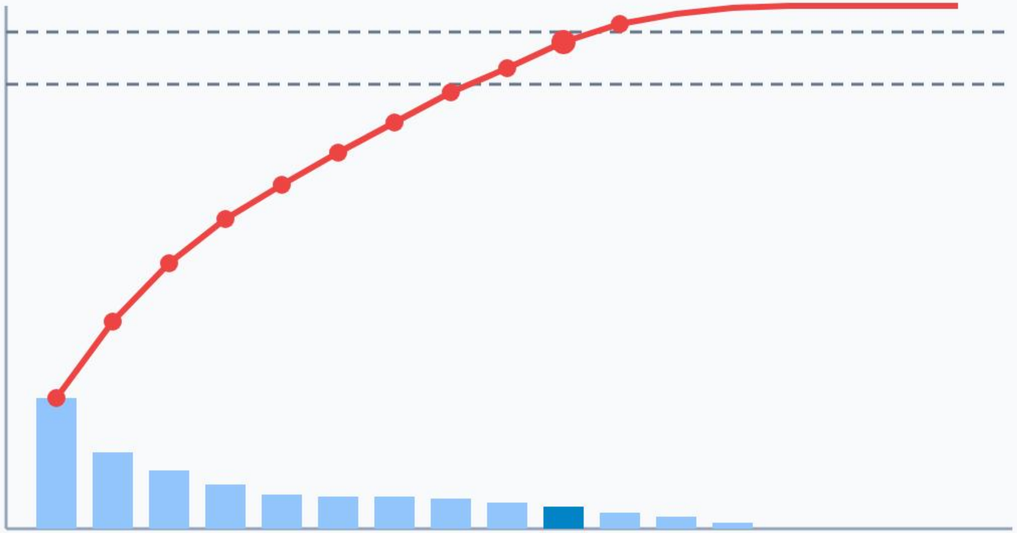
Logistic Regression tối ưu Recall 60%.

Chuẩn Hóa StandardScaler & Lựa Chọn 10 Thành Phần Chính (93.0%)

Ma trận 593 × 17: Gồm 6 biến định lượng/nhị phân, 6 loại bìa và 5 Lvl1.

StandardScaler: Tiên quyết đưa trung bình về 0, phương sai về 1.

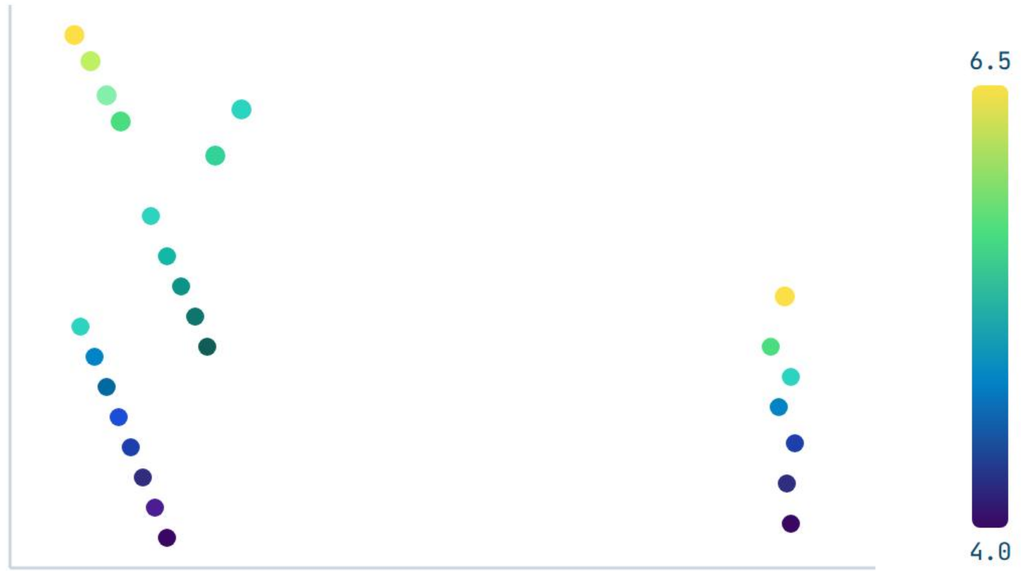
Ngưỡng 85%–95%: 9 PCs đạt 88.0%, 10 PCs đạt 93.0%, 11 PCs đạt 96.4%.



● Phương sai tích lũy (PC10 = 93.0%) ■ Phương sai từng PC (PC1 = 25.0%)

PHẦN 4 // 1.c. MA TRẬN BIẾN ĐỔI & TRỰC QUAN HÓA KHÔNG GIAN 2D (PC1 – PC2)

Phân Tách Hình Học Sách Vs. Phi Sách & Phân Tầng Theo log10(Price)



↔ **Trục hoành PC1:** Phân tách Sách (trái, -1.5 đến +1.5) khỏi Phi sách (phải, ~8.0).

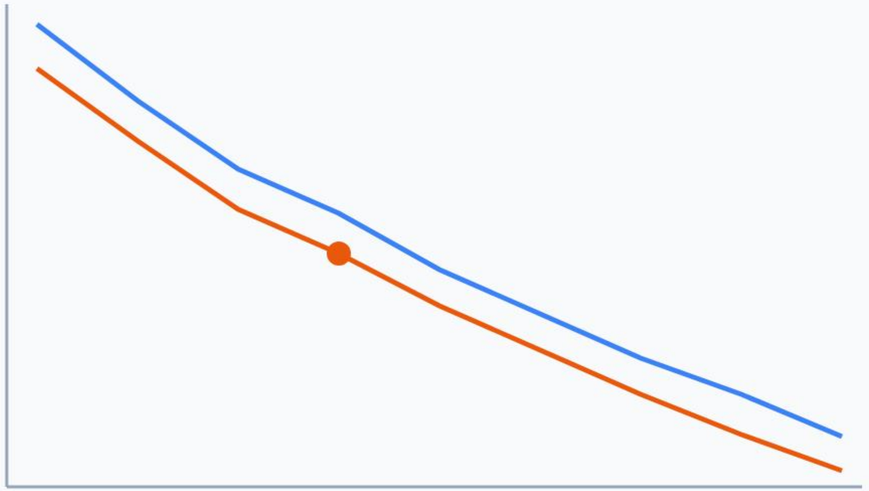
↕ **Trục tung PC2:** Chuyển màu từ tím sẫm (sách mỏng rẻ) lên vàng sáng (Boxset giá cao).

2 dải nghiêng song song: Ứng với Sách Tiếng Việt và Sách Ngoại Văn.

PHẦN 4 // 2.a. CUSTOMER SEGMENTATION / CLUSTERING (ELBOW & SILHOUETTE)

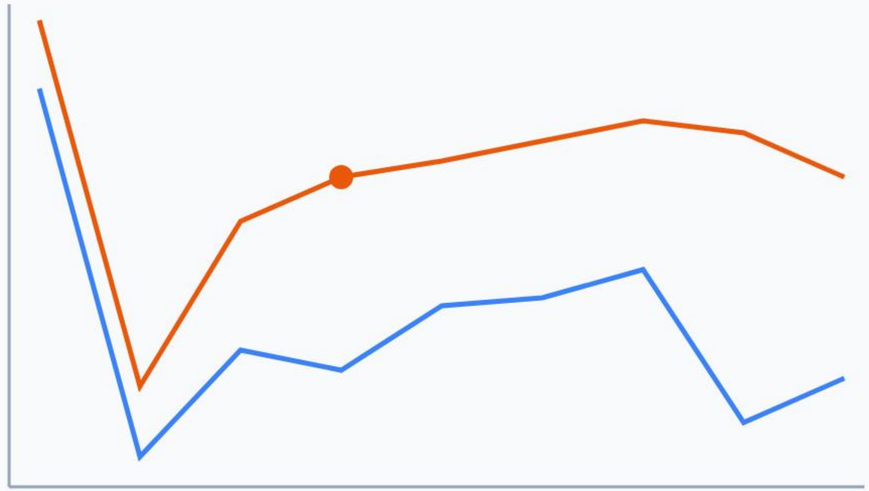
Biểu Đồ Khuỷu Tay (Elbow) & Hệ Số Dáng Điệu (Silhouette) Từ K=2 Đến K=10

Elbow (Inertia / WCSS)



• Dữ liệu gốc (K=5: 4,829.7) • Sau PCA (K=5: 4,120.6)

Silhouette Score



• Dữ liệu gốc (K=5: 0.532) • Sau PCA (K=5: 0.607 - Tối ưu)

PHẦN 4 // BẢNG 4.1: KẾT QUẢ KHẢO SÁT SỐ CỤM K TRÊN DỮ LIỆU GỐC & SAU PCA

Lý Do Chọn K = 5 Tránh Cụm Ngoại Lai Đơn Lẻ (K >= 7)

Số Cụm (K)	Silhouette (Gốc)	Silhouette (Sau PCA)	Inertia / WCSS (Sau PCA)	Cụm Nhỏ Nhất (Sau PCA)
K = 2	0.642	0.668	6,885.12	35 sản phẩm
K = 3	0.498	0.526	5,742.60	35 sản phẩm
K = 4	0.540	0.590	4,738.15	35 sản phẩm
K = 5 (Tối ưu)	**0.532**	**0.607**	**4,120.59**	**17 sản phẩm (>= 3% mẫu)**
K = 6	0.557	0.613	3,412.80	12 sản phẩm
K = 7	0.560	0.620	2,819.45	3 sản phẩm (Ngoại lai)
K = 8	0.572	0.629	2,210.30	1 sản phẩm (Ngoại lai)
K = 9 & K = 10	0.512 / 0.529	0.624 / 0.607	1,635.18 / 1,140.92	1 sản phẩm (Ngoại lai)

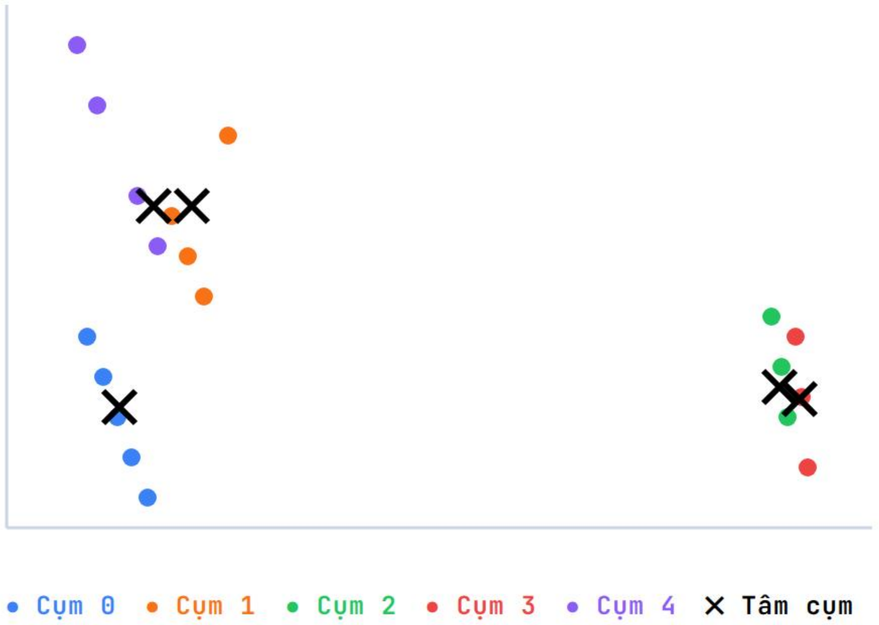
PHẦN 4 // 2.b & BẢNG 4.2: HỒ SƠ ĐẶC TRƯNG THƯƠNG MẠI CỦA 5 PHÂN KHÚC (K = 5)

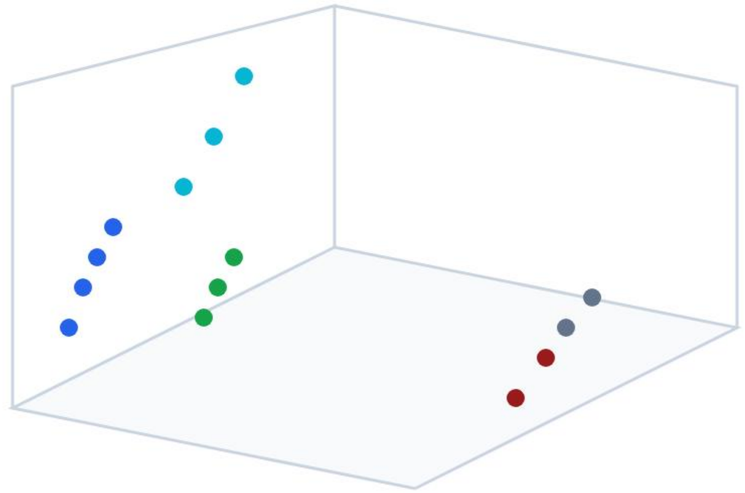
Chi Tiết 5 Phân Khúc Sản Phẩm Sau Khi Phân Cụm K-Means

Cụm	Số SP	Giá TV	Bán TV	Trang TV	Bộ / Quà	Bestseller	Nhóm Hàng Chính (Lvl1)
Cụm 0	442	95,000	3,300	264.0	4% / 13%	27%	SÁCH TIẾNG VIỆT (Đại trà)
Cụm 1	61	301,600	1,400	206.0	3% / 0%	13%	FOREIGN BOOKS
Cụm 2	17	150,000	5,900	0.0	0% / 0%	41%	ĐỒ CHƠI
Cụm 3	18	172,055	6,800	0.0	17% / 0%	50%	VĂN PHÒNG PHẨM - DỤNG CỤ
Cụm 4	55	262,500	1,000	408.0	18% / 24%	7%	SÁCH TIẾNG VIỆT (Cứng/Bộ)

OUTPUT K-MEANS (K = 5) // TRỰC QUAN HÓA PHÂN CỤM TRÊN KHÔNG GIAN 2D & 3D

Mặt Phẳng PC1–PC2 Cùng Tâm Cụm (X) & Không Gian 3 Chiều PC1–PC2–PC3





Không gian 3 chiều (PC1 – PC2 – PC3) tách lớp theo chiều sâu

PHẦN 4 // 3.a & 3.b. SUPERVISED LEARNING: REGRESSION TASKS (BẢNG 4.3)

Dự Báo Giá Bán (log_Price): OLS Vs. Decision Tree Regressor

Mô Hình Hồi Quy (Regression Model)	Loại Mô Hình	MSE	RMSE	R-Squared (R^2)
Linear Regression (OLS)	Tham số (Parametric)	0.0786	0.2803	0.4395 (43.95%)
Decision Tree Regressor (max_depth=5)	**Phi tham số (Non-parametric)**	**0.0754**	**0.2746**	**0.4621 (46.21%)**

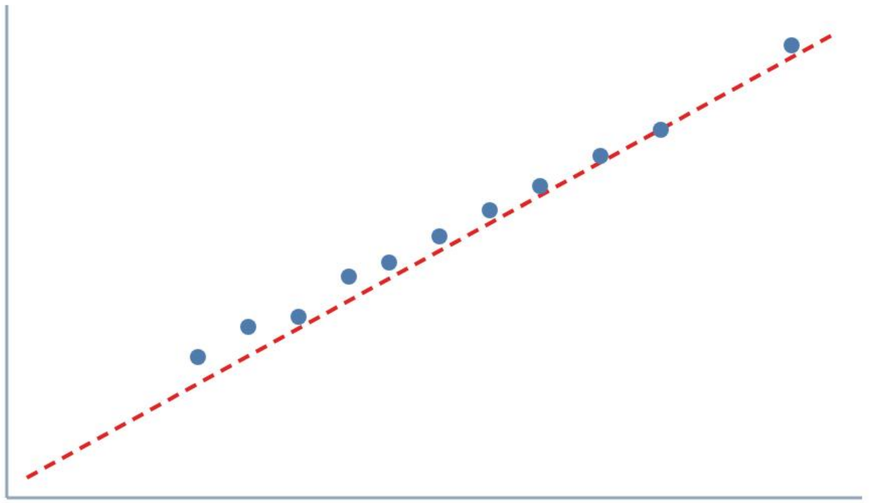
Chống Data Leakage: Loại bỏ Price, Price_clip, Price_per_page, log_PricePerPage khỏi X_reg.

Cấu hình chống Overfitting: Khóa max_depth=5, min_samples_leaf=5, chia Train/Test 80/20.

OUTPUT REGRESSION DIAGNOSTICS (HÀNG TRÊN) // ACTUAL VS. PREDICTED PLOTS

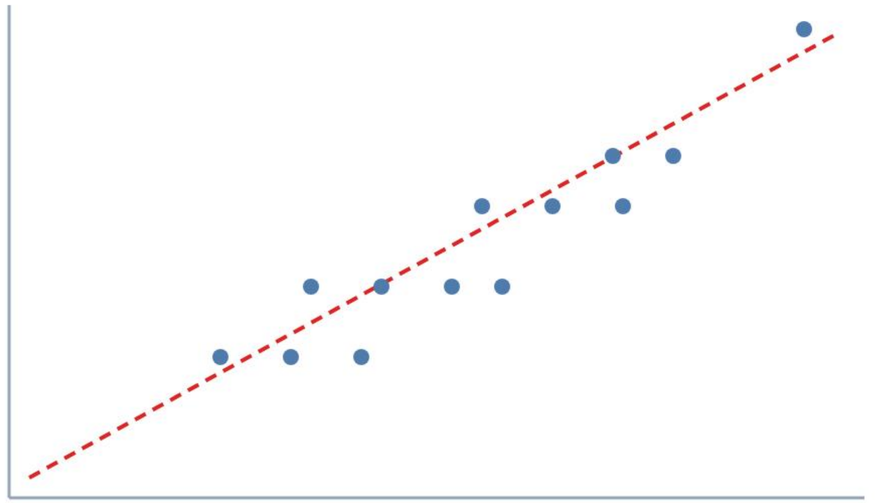
Đối Chiếu Giá Trị log10(Price) Thực Tế Và Dự Báo Với Đường Chéo Lý Tưởng

Linear Regression: Actual vs Predicted



Actual log10(Price) [4.0 → 6.0]

Decision Tree: Actual vs Predicted

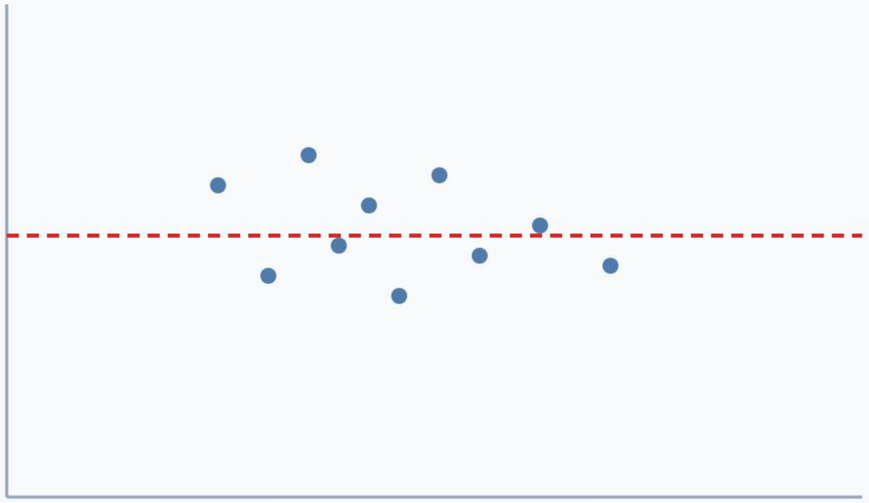


Các dải bậc thang ngang đặc trưng của nút lá Cây quyết định

OUTPUT REGRESSION DIAGNOSTICS (HÀNG DƯỚI) // RESIDUAL PLOTS

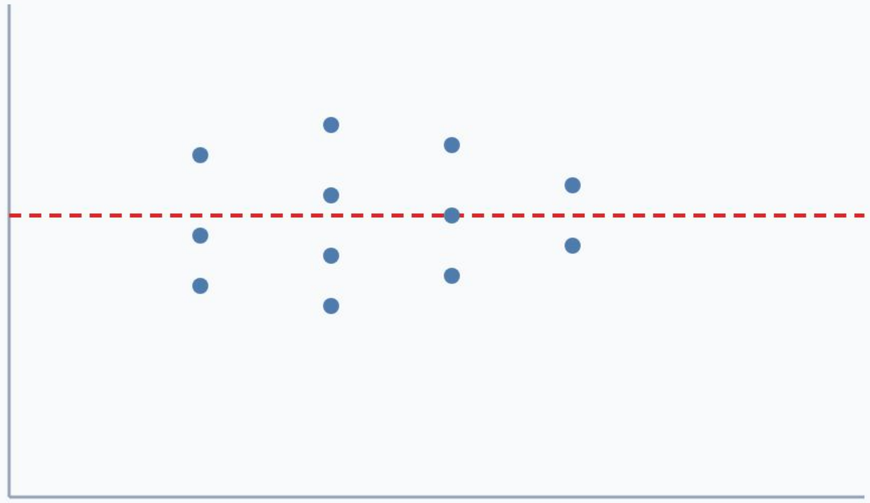
Chẩn Đoán Phần Dư (Residual = Actual − Predicted) Quanh Đường Cơ Sở 0.00

Linear Regression: Residual plot



Phân bố ngẫu nhiên đối xứng [-0.4, +0.4] • Không bị hình phễu

Decision Tree: Residual plot



Phương sai sai số đồng nhất (Homoscedasticity) hợp lệ

PHẦN 4 // 4.a & 4.b. SUPERVISED LEARNING: CLASSIFICATION TASKS (BẢNG 4.4)

Báo Cáo Phân Loại Bestseller Trên Tập Kiểm Thử (119 Mẫu • Stratify 80/20)

Mô Hình Phân Loại	Nhãn Lớp (Class)	Precision	Recall	F1-Score	Support	Accuracy / Macro F1
Logistic Regression	Thường (0)	0.81	0.57	0.67	89	Accuracy: 0.58
Logistic Regression (Chọn)	**Bestseller (1)**	0.32	0.60	0.42	**30**	Macro F1: 0.54
Decision Tree Classifier	Thường (0)	0.75	0.67	0.71	89	Accuracy: 0.59
Decision Tree Classifier	Bestseller (1)	0.26	0.33	0.29	30	Macro F1: 0.50

OUTPUT CONFUSION MATRIX // KẾT QUẢ DỰ ĐOÁN TRÊN TẬP KIỂM THỬ (119 MẪU)

Ma Trận Nhầm Lẫn: Logistic Regression (Bắt Đúng 18/30) Vs. Decision Tree (10/30)

Logistic Regression

Thực tế \ Dự đoán	Dự đoán: Thường	Dự đoán: Bestseller
Thực tế: Thường	51	38
Thực tế: Bestseller	12	18

Decision Tree

Thực tế \ Dự đoán	Dự đoán: Thường	Dự đoán: Bestseller
Thực tế: Thường	60	29
Thực tế: Bestseller	20	10

TỔNG KẾT NGHIÊN CỨU // NHỮNG GÌ NGHIỆM RA ĐƯỢC VỀ DỮ LIỆU & THỊ TRƯỜNG

3 Phát Hiện Thực Tế Rút Ra Sau Khi Khám Phá Dữ Liệu Fahasa

Giá Rẻ Chưa Chắc Bán Chạy

Tương quan giá và lượng bán rất yếu (-0.30).

Nghịch Lý Nhóm Phi Sách

VPP và Đồ chơi ít mẫu nhưng bán trung vị cao nhất.

Đặc Thù Định Dạng & Ngành

Bìa mềm cùng SGK, Thiếu nhi, Manga áp đảo Top 25%.

TỔNG KẾT NGHIÊN CỨU // NHỮNG GÌ NGHIỆM RA ĐƯỢC VỀ KHOA HỌC DỮ LIỆU & MÔ HÌNH

4 Bài Học Kỹ Thuật Đúc Kết Từ Thực Nghiệm Tiền Xử Lý & Học Máy

1. Dữ Liệu Sạch Quyết Định

Lọc 5 dòng lỗi nhân giá giúp R^2 tăng gấp đôi lên 46.21%.

2. Không Xóa Khuyết Tùy Tiện

Điền khuyết theo is_book bảo toàn nhóm VPP và Đồ chơi.

3. PCA Khử Nhiễu Phân Cụm

Giảm chiều từ 17 xuống 10 PCs nâng Silhouette lên 0.607.

4. Chọn Đúng Thước Đo

Dữ liệu lệch phải ưu tiên Recall (0.60) và F1 thay vì Accuracy.



Cảm Ơn Cô Và Các Bạn Đã Lắng Nghe!

Báo Cáo Tiểu Luận Khoa Học Dữ Liệu • Nhóm 4 • Đại Học Công Nghiệp TP.HCM

Project Team Github Repositories: https://github.com/jnzm246/Project_Team_Group_4